Bruktbilpris estimator

Jonas Berdal Holm, Shahoz Shwana, Alexander Dahle 5.10.26

1: BESKRIV PROBLEMET

OMFANG / *SCOPE*

Målet med prosjektet er å lage en nettside hvor man kan estimere prisen på en bruktbil basert på noen få opplysninger: merke, modell, årsmodell, kilometerstand, girkasse, drivstofftype og motorstørrelse.

Maskinlæring er en veldig god løsning på dette siden prisen på en bruktbil bestemmes av mange faktorer som påvirker hverandre, noe som gjør det vanskelig å komme fram til en pris selv. En maskinlæringsmodell kan komme fram til et estimat basert på historiske data.

Løsningen er ment for privatpersoner som skal kjøpe eller selge en bruktbil. Selgere kan bruke det til å sette en realistisk pris på bilen mens kjøpere kan bruke det til å vurdere om det er en rimelig pris for bilen de kjøper, og kan da bruke estimatet i forhandlinger.

I dag finnes det flere tjenester for verdivurdering av bruktbiler. Store annonsesider som Auto Trader i Storbritannia og Kelley Blue Book i USA tilbyr prisestimater, og innkjøpstjenester som WeBuyAnyCar og norske Nettbil gir et tilbud basert på bilens opplysninger. Bilforhandlere bruker i tillegg egne bransjeverktøy. Disse tjenestene bygger ofte på store salgsdatabaser, men metodene bak er sjelden åpne, og innkjøpstjenestene har en egeninteresse i å gi et lavt estimat.

Uten maskinlæring må man finne verdien manuelt, typisk ved å søke opp tilsvarende biler på annonsesider, sammenligne prisene og justere skjønnsmessig for forskjeller i kjørelengde, alder og utstyr, eller ved å be en forhandler om en vurdering. Dette er tidkrevende og subjektivt, og resultatet avhenger av hvilke annonser man tilfeldigvis finner. En maskinlæringsmodell gjør i prinsippet det samme, nemlig å sammenligne med lignende biler, men systematisk og basert på titusenvis av eksempler.

Det som kan gjøre produktet til en suksess, er at det er raskt, gratis og nøytralt. Brukeren får svar på sekunder uten registrering, og tjenesten har ingen egeninteresse i om prisen er høy eller lav. Nettsiden viser dessuten hvor usikkert estimatet er, i stedet for å gi et tilsynelatende presist tall. For å lykkes i et ekte marked må modellen likevel trenes på oppdaterte, lokale data, siden datasettet vårt er fra det britiske markedet rundt 2020 (se del 4).

Prosjektet krever lite ressurser. Datasettet er gratis tilgjengelig, all trening ble gjort på en vanlig bærbar datamaskin i løpet av noen minutter, og nettsiden kjører på en gratis hostingtjeneste.

METRIKKER

Hovedmetrikken er gjennomsnittlig absolutt feil (MAE), altså hvor mange pund estimatet i snitt avviker fra den faktiske prisen. MAE er valgt fordi den er lett å forstå for en vanlig bruker («estimatet bommer typisk med £X»), og fordi den ikke straffer enkelte store feil like hardt

som kvadratisk avvik (MSE). Som tilleggsmål bruker vi R^2, som angir hvor stor andel av variasjonen i pris modellen forklarer. $R^2 = 1$ er perfekt, mens $R^2 = 0$ tilsvarer å gjette gjennomsnittsprisen for alle biler. Vi ser også på den gjennomsnittlige prosentvise feilen, siden en feil på £1 000 betyr mye mer for en billig bil enn for en dyr.

Vi satte to krav for at modellen skal regnes som vellykket: den må være klart bedre enn en enkel baseline som gjetter medianprisen for alle biler, og den må ha en MAE under £1 500 på testdata. For nettsiden er kravet at estimatet vises umiddelbart etter at brukeren trykker på knappen.

2: DATA

Datasett

Vi brukte datasettet «100,000 UK Used Car Data set» fra Kaggle, som er publisert som public domain. Det består av ni CSV-filer, én per bilmerke (Audi, BMW, Ford, Hyundai, Mercedes, Skoda, Toyota, Vauxhall og Volkswagen), med til sammen 99 187 bruktbilannonser fra Storbritannia. Hver annonse inneholder bilmodell, årsmodell, pris i pund, girkasse, kjørelengde i miles, drivstofftype, årlig bilavgift (tax), offisielt drivstofforbruk (mpg) og motorstørrelse i liter.

Oppgaven er et regresjonsproblem innen veiledet læring. Målvariabelen (label) er prisen, som allerede finnes i hver annonse, så det var ikke nødvendig å merke data manuelt. Prisene er satt av selgerne selv og er derfor annonsepriser, ikke nødvendigvis faktiske salgspriser. Det gir en viss støy i dataene. Med nesten 100 000 eksempler er datamengden god for en modell av denne typen.

Datasettet inneholder ingen personopplysninger, bare egenskaper ved bilene, så det er ingen personvernhensyn knyttet til dataene. Opplysningene brukeren skriver inn på nettsiden, lagres ikke.

Datarens

Datasettet består av ni separate CSV-filer, én per bilmerke. Filene ble slått sammen til én tabell, og det ble lagt til en kolonne for bilmerke, siden merket bare kom frem av filnavnet. Under sammenslåingen oppdaget vi at Hyundai-filen brukte kolonnenavnet tax(£) i stedet for tax. Kolonnen ble omdøpt slik at alle filene fikk samme struktur. Det sammenslåtte datasettet inneholdt 99 187 biler.
For å finne feil og uvanlige verdier undersøkte vi minimums- og maksimumsverdiene for hver tallkolonne. Følgende rader ble fjernet:

Problem	**Antall**	**Begrunnelse**
Årsmodell 2060	1	Umulig verdi, trolig en skrivefeil. Riktig årstall kunne ikke fastslås.
Motorstørrelse 0 liter (ikke elbil)	270	Umulig for biler med forbrenningsmotor. To elbiler med 0 liter ble beholdt, siden verdien er korrekt for dem.

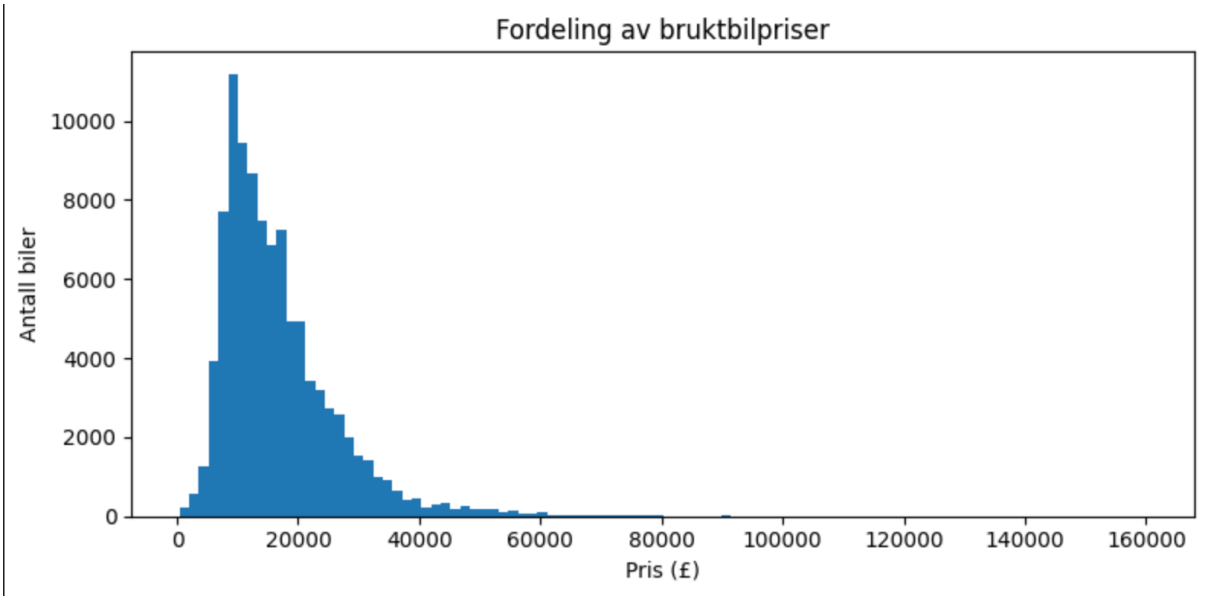
Årsmodell før 2000	22	Ikke feil, men for få eksempler til at modellen kan gi pålitelige estimater. Eldre biler prises dessuten ofte etter tilstand og samlerverdi, som datasettet ikke inneholder.
Duplikater	1470	Identiske rader, trolig samme annonse registrert flere ganger. Duplikater kan havne både i trenings- og testsettet og gi et for optimistisk bilde av modellens ytelse.

Tabell 1

Etter rensingen besto datasettet av 97 424 biler. Løsningen er dermed avgrenset til biler fra 2000 og nyere.

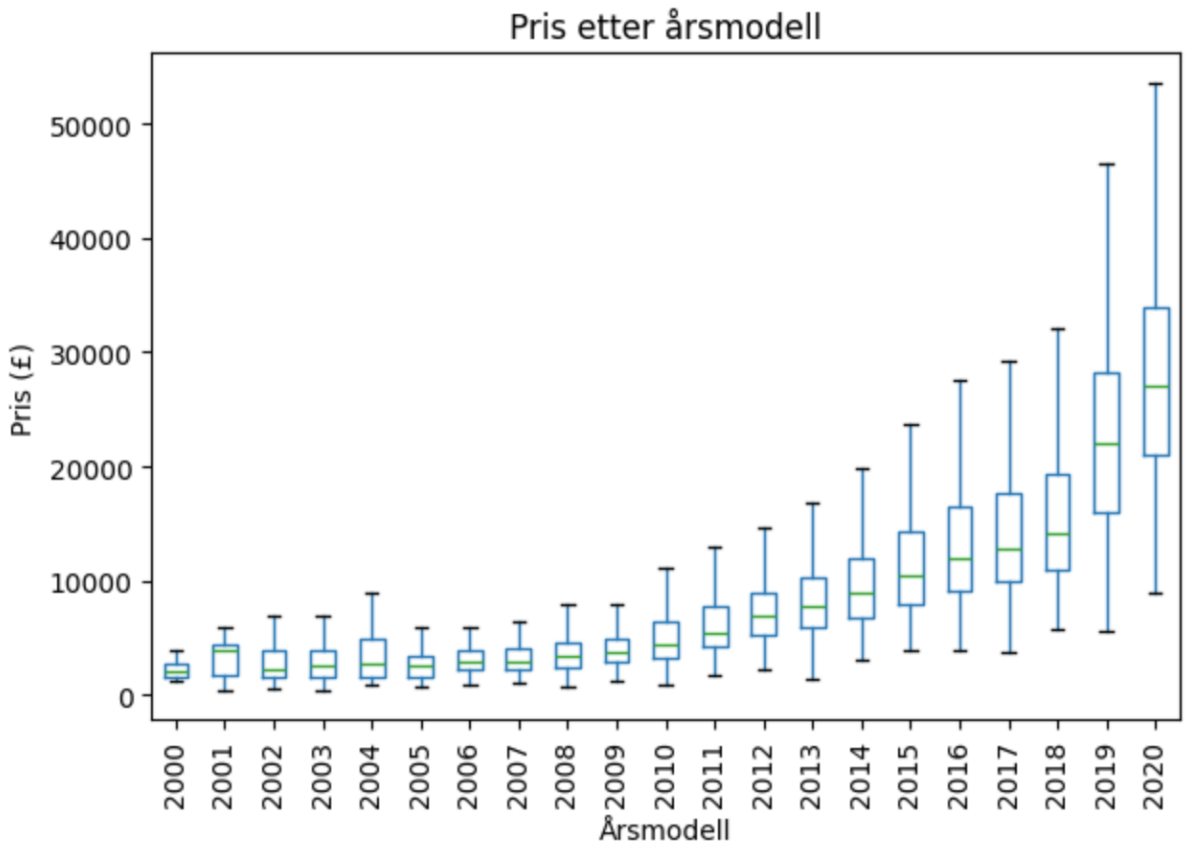
Utforskende analyse

Prisfordelingen er høyreskjev (Figur 1). De fleste bilene koster mellom £10 000 og £20 000, mens et lite antall dyre modeller gir en lang hale mot høyere priser. Medianprisen (£14 480) er derfor lavere enn gjennomsnittet (£16 776).



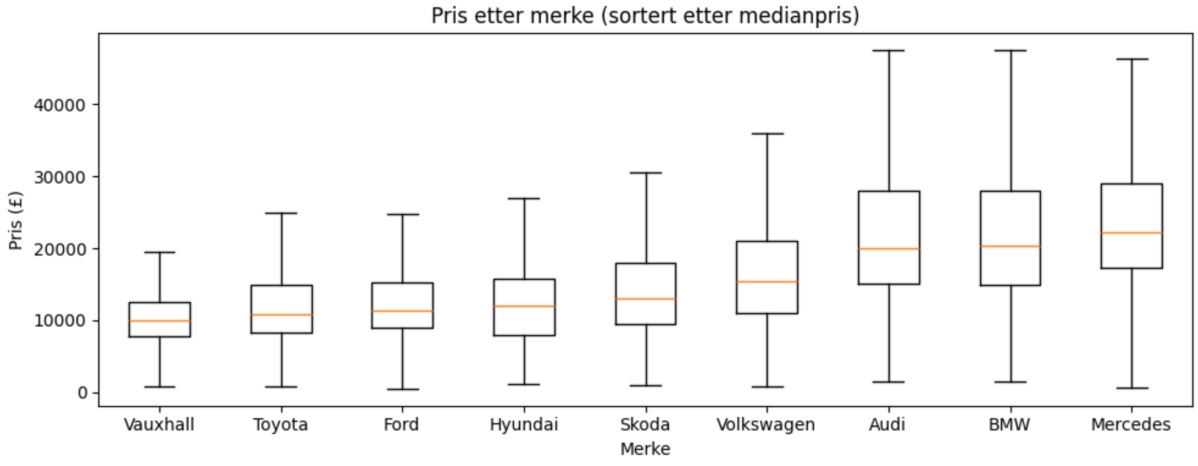
Figur 1

Figur 2 viser at prisen øker med årsmodellen, men sammenhengen er ikke-lineær. For biler fra 2000 til 2009 er medianprisen nesten konstant, mens den stiger kraftig for de nyeste årsmodellene. Dette gjenspeiler at biler taper mest verdi de første årene. Spredningen i pris er også større for nyere biler, trolig fordi forskjellene mellom billige og dyre modeller er størst når bilene er nye. Den ikke-lineære sammenhengen tilsier at trebaserte modeller kan egne seg bedre enn lineære modeller.



Figur 2

Figur 3 viser at merket har stor betydning for prisen. Mercedes, Audi og BMW er dyrest, mens Vauxhall, Toyota, Hyundai og Ford er blant de billigste. Forskjellen skyldes likevel ikke bare merket, siden premiumbilene i datasettet også kan være nyere eller ha større motorer. Nettopp derfor er en modell som ser på alle egenskapene samtidig, nyttig.



Figur 3

Valg av egenskaper

Datasettet inneholder også kolonnene mpg (offisielt drivstofforbruk) og tax (årlig bilavgift i Storbritannia). Disse ble ikke brukt som egenskaper i modellen, av tre grunner.
For det første kjenner en vanlig bruker sjelden disse verdiene for sin egen bil. Siden nettsiden bare kan bruke informasjon brukeren faktisk kan oppgi, ville det gjort løsningen vanskeligere å bruke.
For det andre er verdiene i stor grad bestemt av egenskaper som allerede er med i modellen, som bilmodell, årsmodell, motorstørrelse og drivstofftype. De ville derfor tilført lite ny informasjon.
For det tredje inneholdt mpg tydelige feil, som en minimumsverdi på 0,3 miles per gallon. Bilavgiften er dessuten bestemt av britiske regler, så den ville gjort modellen mer knyttet til det britiske markedet.

Representasjon

Kategoriske variabler (merke, modell, girkasse og drivstoff) ble gjort om til tall med one-hot encoding. Det ble valgt fremfor å gi hver kategori et nummer, fordi kategoriene ikke har noen naturlig rekkefølge, og nummerering ville fått modellen til å tolke en rekkefølge og avstand som ikke finnes.

3: MODELLERING

Modeller

Baseline. For å vurdere om maskinlæring faktisk gir en forbedring, ble modellene sammenlignet med en enkel baseline som estimerer medianprisen fra treningsdataene for alle biler, uavhengig av bilens egenskaper. Medianen ble valgt fremfor gjennomsnittet fordi prisfordelingen er høyreskjev (Figur 1), og medianen påvirkes mindre av de få dyre bilene. En modell må være klart bedre enn denne baselinen for å ha noen verdi.
Ridge-regresjon. Ridge er en lineær modell som estimerer prisen som en vektet sum av egenskapene, for eksempel et fast beløp per årsmodell og et fast fradrag per mile. Ridge legger i tillegg inn en straff mot store vekter (regularisering), som gjør modellen mer stabil når det er mange egenskaper, slik vi får etter one-hot encoding av bilmodellene. Den ble tatt med som en enkel og lett tolkbar referansemodell.
Random forest. Random forest består av mange beslutningstrær. Hvert tre deler dataene opp gjennom en rekke ja/nei-spørsmål, for eksempel om bilen er nyere enn en viss årsmodell eller har kjørt mer enn et visst antall miles, og ender i et prisestimat. Hvert tre trenes på et tilfeldig utvalg av dataene, og det endelige estimatet er gjennomsnittet av alle trærne. Det gjør modellen mindre utsatt for overtilpasning enn ett enkelt tre.
Gradient boosting. Gradient boosting bygger også på beslutningstrær, men trener dem etter hverandre. Hvert nytt tre forsøker å rette opp feilene til de foregående trærne, slik at

modellen gradvis blir mer nøyaktig. Vi brukte scikit-learn sin HistGradientBoostingRegressor, som er optimalisert for store datasett.
De trebaserte modellene ble valgt fordi den utforskende analysen viste at sammenhengen mellom årsmodell og pris er ikke-lineær (Figur 2). Beslutningstrær kan fange opp slike knekkpunkter og samspill mellom egenskaper, for eksempel at verditapet per år er ulikt for ulike merker.

Resultater

Modell	MAE	R^2
Baseline	£6 789	-0,050
Ridge	£2 288	0,062
Random forest	£1 402	0,947
Gradient boosting	£1 349	0,949
Gradient boosting (tunet)	£1 306	0,952

Tabell 2

For å sikre at forskjellene mellom modellene ikke skyldtes én tilfeldig oppdeling av dataene, ble modellene også evaluert med 5-fold kryssvalidering på treningsdataene. Gradient boosting hadde lavest MAE (£1 385 ± £25), og forskjellen til random forest var større enn variasjonen mellom foldene.

Hyperparametrene til gradient boosting ble tunet med et rutenettsøk (GridSearchCV) over læringsrate, antall trær og maksimalt antall blader per tre, med 3-fold kryssvalidering. Den beste kombinasjonen (læringsrate 0,05, 600 trær og 63 blader) reduserte MAE på testsettet fra £1 349 til £1 306. Siden de beste verdiene lå i ytterkanten av søkeområdet, kan et utvidet søk gi ytterligere forbedring.

Figur 4 viser permutation importance for den endelige modellen, målt som økningen i MAE når verdiene til én egenskap blandes tilfeldig. Motorstørrelse og årsmodell er de viktigste egenskapene. Motorstørrelse fungerer trolig som et mål på bilens klasse og utstyrsnivå. Metoden undervurderer egenskaper som overlapper, som merke og modell, eller årsmodell og kjørelengde, fordi informasjonen delvis finnes i den andre egenskapen. Alle egenskapene bidro positivt og ble beholdt.

Tuning

Hyperparametrene til gradient boosting ble tunet med et rutenettsøk (GridSearchCV) over læringsrate (0,05 og 0,1), maksimalt antall trær (300 og 600) og maksimalt antall blader per tre (31 og 63), med 3-fold kryssvalidering. Den beste kombinasjonen var læringsrate 0,05, 600 trær og 63 blader, og den reduserte MAE på testsettet fra £1 349 til £1 306. Siden to av de beste verdiene lå i ytterkanten av søkeområdet, kan et utvidet søk gi en ytterligere, trolig liten, forbedring.

Den endelige modellen har en MAE på £1 306 og R^2 på 0,952, og den oppfyller dermed begge suksesskriteriene fra del 1.

Feilanalyse

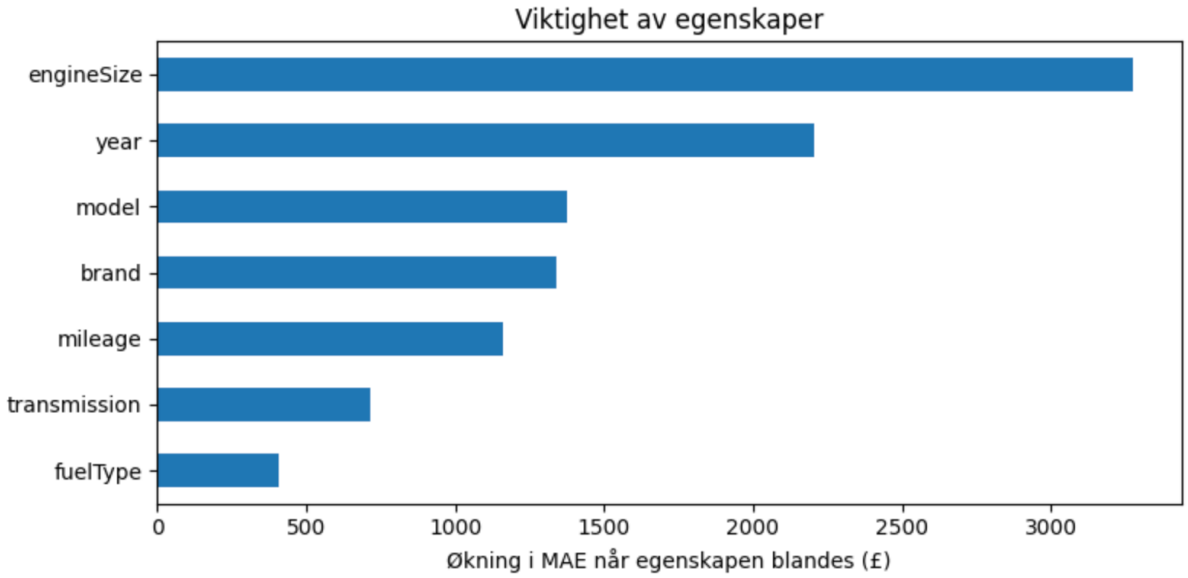
For å se hvor modellen bommer, regnet vi ut feilen for hver bil i testsettet, både i pund og i prosent av prisen. I pund er feilen minst for Vauxhall (£751) og størst for Mercedes (£2 056). Målt i prosent er forskjellene imidlertid små: alle merkene ligger mellom 7,4 og 9,0 %. Modellen er altså omtrent like god for alle merkene relativt sett, og den høyere feilen i pund for premiummerkene skyldes hovedsakelig at bilene er dyrere.

Prisklasse	Gjennomsnittlig feil (£)	Gjennomsnittlig feil (%)
£0-10 000	£653	9,4%
£10 000-20 000	£1 070	7,3%
£20 000-30 000	£1 868	7,6%
£30 000-50 000	£3 241	8,7%
Over £50 000	£5 880	8,9%

Tabell 3: Gjennomsnittlig feil per prisklasse på testsettet

FEATURE IMPORTANCE

Figur 4 viser permutation importance for den endelige modellen, målt som økningen i MAE når verdiene til én egenskap blandes tilfeldig mellom bilene. Motorstørrelse (ca. £3 300) og årsmodell (ca. £2 200) er de viktigste egenskapene, fulgt av modell, merke og kjørelengde. Motorstørrelse fungerer trolig som et mål på bilens klasse og utstyrsnivå. Metoden undervurderer egenskaper som overlapper, som merke og modell eller årsmodell og kjørelengde, fordi informasjonen delvis finnes i den andre egenskapen. Alle egenskapene bidro positivt og ble beholdt.

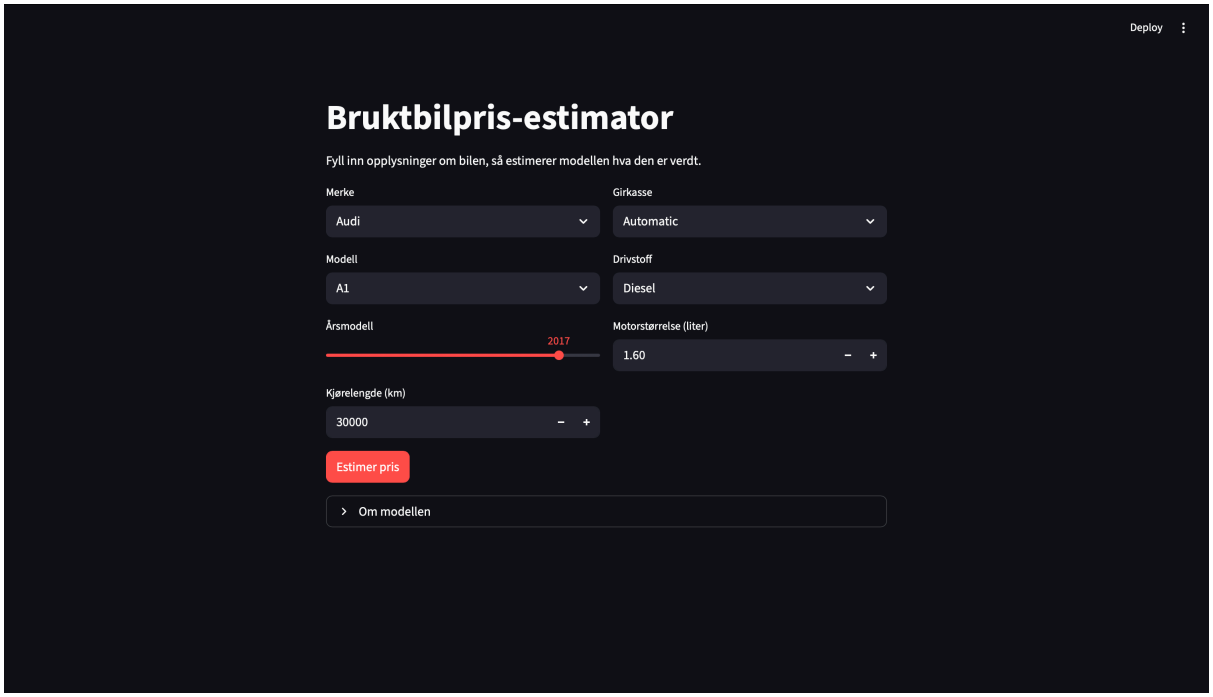


Figur 4

4: DEPLOYMENT

Den endelige modellen ble lagret med joblib, sammen med en fil (meta.json) som inneholder listen over merker og modeller og den gjennomsnittlige prosentvise feilen. Nettsiden er laget med Streamlit og er publisert på Streamlit Community Cloud: . All kode, data og dokumentasjon ligger i et offentlig GitHub-repository: https://github.com/678281/bruktbilpris-estimator. README-filen beskriver hvordan man reproduserer analysen og kjører nettsiden selv. Pakkeversjonene er låst i requirements.txt, siden en modell som er lagret med én versjon av scikit-learn, ikke nødvendigvis kan lastes inn med en annen.

Brukeren velger merke, modell, girkasse og drivstoff fra nedtrekksmenyer, der modellmenyen bare viser modeller for det valgte merket. Årsmodell velges med en glidebryter, og kjørelengde oppgis i kilometer og regnes om til miles før prediksjonen. Nettsiden viser den estimerte prisen og et typisk prisområde basert på modellens gjennomsnittlige prosentvise feil (Figur 5). Under «Om modellen» står det at prisene gjelder det britiske markedet rundt 2020.



Figur 5: Bilde av nettsiden

5: REFERANSER

- Datasett: «100,000 UK Used Car Data set», Kaggle. [https://www.kaggle.com/datasets/adityadesai13/used-car-dataset-ford-and-mercedes]
- Pedregosa m.fl. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830. https://scikit-learn.org
- pandas: https://pandas.pydata.org
- matplotlib: https://matplotlib.org

- Streamlit: https://streamlit.io
- Bruk av KI: Vi brukte KI-assistenten Claude (Anthropic) gjennom hele prosjektet: som hjelp til å skrive og forklare koden for dataanalyse, modellering og nettsiden, til feilsøking av utviklingsmiljøet, og til å skrive utkast til store deler av teksten i denne rapporten, som vi deretter har gjennomgått og redigert.